

后端大模型接入功能详解

文档说明

本文档说明语联灵犀后端系统中大模型接入相关的各个部分的功能。

文档版本：v1.0

最后更新：2024年

适用系统：语联灵犀后端系统

目录

- [1. 概述](#)
- [2. 核心模块功能](#)
- [3. 工作流程](#)
- [4. 配置说明](#)

一、概述

1.1 功能定位

大模型接入层是语联灵犀后端系统的核心组件，主要功能包括：

- 意图识别**：将用户的自然语言输入转换为结构化的工具调用指令
- 多模型支持**：支持多种大模型服务（OpenAI API、本地模型等）
- 智能降级**：当大模型不可用时，自动切换到基于规则的意图识别
- 工具调度**：根据大模型识别的意图，调度相应的工具执行任务

1.2 支持的接入方式

1. OpenAI 兼容 API

- 阿里云百炼平台（DashScope）
- OpenAI 官方 API
- 其他兼容 OpenAI 格式的 API 服务

2. 本地模型

- 通过 HTTP API 调用的本地部署模型
- 支持 Qwen、ChatGLM 等模型

3. 降级方案

- 基于规则的意图识别
- 无需大模型即可运行

二、核心模块功能

2.1 LLMService (大模型服务抽象层)

文件位置： app/core/llm_service.py

功能概述

提供统一的大模型调用接口，支持多种大模型服务，并具备完善的降级机制。

主要功能

1. 统一调用接口

- 提供统一的 `chat()` 方法调用大模型
- 自动识别并选择调用方式 (OpenAI API 或本地模型)
- 支持温度参数调节，控制输出随机性

2. 多模型支持

- OpenAI 兼容 API：支持调用 OpenAI 官方 API 和兼容格式的 API (如 DashScope)
- 本地模型：支持通过 HTTP API 调用本地部署的模型
- 自动检测并选择合适的调用方式

3. JSON 格式响应

- 自动检测提示词中的 JSON 格式要求
- 自动启用 JSON 格式响应模式
- 确保返回结果符合 JSON 规范

4. 降级机制

- 当未配置 API Key 时，自动使用规则识别
- 当 API 调用失败时，自动降级到规则识别
- 规则识别支持：新闻查询、天气查询、股票查询、计算等

5. 错误处理

- 完善的错误捕获和处理机制
- 详细的错误日志记录
- 认证错误时提供配置提示

当大模型不可用时，系统自动使用基于规则的意图识别：

- **新闻查询**：识别关键词"新闻"、"资讯"，提取查询关键词和数量限制
- **天气查询**：识别关键词"天气"、"气温"，提取城市名称和查询天数
- **股票查询**：识别关键词"股票"，提取股票代码和查询天数
- **计算**：识别关键词"计算"或数学运算符，提取计算表达式

2.2 PromptTemplate（提示词模板管理）

文件位置： app/core/prompt.py

功能概述

管理所有与大模型交互的提示词模板，包括意图识别提示词、工具选择提示词等。

主要功能

1. 意图识别提示词

- 定义系统角色和职责
- 列出所有可用工具及其功能说明
- 说明每个工具的参数要求
- 提供返回格式示例（单工具、多工具、计算等）

2. 工具说明

- **weather**：天气查询工具，支持查询指定城市的天气信息（7天预报）
- **news**：新闻检索工具，支持根据关键词检索新闻
- **stock**：股票数据查询工具，支持查询股票历史价格数据
- **calculate**：数值计算工具，支持执行数学计算
- **document**：文档生成工具，支持生成报告、邮件、总结等文档

3. 多工具支持

- 支持识别多个任务并返回工具链
- 说明工具链的执行顺序
- 支持工具间的数据传递（如前一个工具的结果作为后一个工具的输入）

4. 工具选择提示词

- 支持多轮工具调用场景
- 根据之前的工具执行结果，选择下一个要调用的工具

2.3 Agent（智能 Agent）

功能概述

系统的核心调度器，负责协调大模型和工具调度，实现从用户自然语言输入到工具执行的完整流程。

主要功能

1. 意图识别

- 接收用户的自然语言输入
- 调用大模型进行意图识别
- 解析大模型返回的 JSON 结果
- 提取工具名称和参数

2. 单工具调用

- 识别单个工具需求
- 提取并验证工具参数
- 调用相应工具执行任务
- 返回工具执行结果

3. 多工具链式调用

- 识别包含多个任务的用户需求
- 按顺序执行多个工具
- 支持工具间的数据传递（如将天气数据传递给文档生成工具）
- 记录工具链执行信息

4. 参数处理

- **天气工具**：验证和补全城市名称、查询天数
- **新闻工具**：验证和补全查询关键词、数量限制
- **股票工具**：支持股票名称到代码的映射（如“贵州茅台”→“600519”）
- **计算工具**：提取和验证计算表达式
- **文档工具**：处理模板类型、内容提示、上下文数据

5. 多任务检测

- 检测用户输入是否包含多个任务
- 识别不同任务类型的关键词
- 优先处理计算任务

6. 降级处理

- 当大模型调用失败时，自动使用规则识别
- 当 JSON 解析失败时，自动使用规则识别
- 确保系统始终可用

2.4 Config (配置管理)

文件位置：app/config.py

功能概述

管理应用配置，支持从环境变量和 .env 文件读取配置。

大模型相关配置

1. LLM_API_KEY

- 大模型 API Key
- 用于认证大模型 API 请求

2. LLM_BASE_URL

- API 基础 URL
- 如果未配置，使用默认的 DashScope 端点
- 如果配置为本地地址，会调用本地模型

3. LLM_MODEL

- 模型名称
- 指定要使用的大模型（如 qwen-turbo、gpt-3.5-turbo）

三、工作流程

3.1 单工具调用流程

用户输入自然语言

↓
Agent 接收输入

↓
构建意图识别提示词（包含工具列表、用户需求、格式要求）

↓
调用大模型 API

↓
大模型返回 JSON 格式的意图识别结果

↓
解析 JSON，提取工具名称和参数

↓
处理参数（验证、补全、转换）

↓
调用相应工具

↓
返回工具执行结果

3.2 多工具链式调用流程

```
用户输入包含多个任务的自然语言
↓
Agent 检测到多任务
↓
调用大模型识别所有需要的工具
↓
大模型返回工具链（按顺序排列）
↓
按顺序执行每个工具
↓
如果当前工具是文档工具，将前一个工具的结果作为上下文数据
↓
返回所有工具的执行结果
```

3.3 降级流程

```
用户输入自然语言
↓
尝试调用大模型
↓
如果未配置 API Key 或调用失败
↓
使用规则识别（基于关键词匹配）
↓
提取工具名称和参数
↓
调用相应工具
↓
返回工具执行结果
```

四、配置说明

4.1 环境变量配置

在 backend/.env 文件中配置：

```
# 大模型配置
LLM_API_KEY=your-api-key-here
LLM_BASE_URL=https://dashscope.aliyuncs.com/compatible-mode/v1
LLM_MODEL=qwen-turbo
```

4.2 配置示例

使用阿里云百炼平台 (DashScope)

```
LLM_API_KEY=sk-xxxxxxxxxxxxxx  
LLM_BASE_URL=https://dashscope.aliyuncs.com/compatible-mode/v1  
LLM_MODEL=qwen-turbo
```

使用 OpenAI 官方 API

```
LLM_API_KEY=sk-xxxxxxxxxxxxxx  
LLM_BASE_URL=https://api.openai.com/v1  
LLM_MODEL=gpt-3.5-turbo
```

使用本地模型

```
LLM_API_KEY=not-needed  
LLM_BASE_URL=http://localhost:8001/v1  
LLM_MODEL=Qwen/Qwen-7B-Chat
```

不使用大模型（降级方案）

```
# 不设置 LLM_API_KEY 或设置为空  
LLM_API_KEY=
```

4.3 配置说明

- **LLM_API_KEY**：大模型 API Key，如果未配置，系统会自动使用降级方案
- **LLM_BASE_URL**：API 基础 URL，如果未配置，默认使用 DashScope 端点
- **LLM_MODEL**：模型名称，根据实际使用的大模型设置

附录

A. 文件清单

- app/core/llm_service.py : 大模型服务抽象层
- app/core/prompt.py : 提示词模板管理
- app/core/agent.py : 智能 Agent
- app/config.py : 配置管理

B. 相关文档

- docs/LLM_INTEGRATION.md : 大模型接入指南
- backend/ENV_SETUP.md : 环境配置说明

- backend/QUICK_START.md : 快速开始指南
-

文档结束